

Laporan Praktikum Kontrol Cerdas

Nama : Inggar Mahesa Yudanto
Nim : 224308084
Kelas : TKA – 7D
Akun Github (Tautan) : <https://github.com/Inggarmahesa>
Student Lab Assistant : -

1. Judul Percobaan

Reinforcement Learning for Autonomous Control.

2. Tujuan Percobaan

Tujuan dari praktikum “*Reinforcement Learning for Autonomous Control*”, mahasiswa diharapkan mampu:

1. Mahasiswa dapat mengetahui pengimplementasian agen RL dalam menggunakan algoritma *Deep Q-Network* (DQN).
2. Mahasiswa dapat menerapkan *Convolutional Neural Network* (CNN) sebagai klarifikasi objek.
3. Mahasiswa dapat Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
4. Mahasiswa dapat Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.

3. Landasan Teori

Machine learning adalah pembelajaran mesin yang sangat membantu dalam menyelesaikan masalah, membuat mudah dalam mengerjakan sesuatu. *Machine learning* bermula saat manusia memikirkan bagaimana cara agar komputer dapat belajar dari pengalaman atau dapat mengingat apa saja yang barusan dioperasikan di komputer tersebut (Telaumbanua dkk., 2020). *Reinforcement learning* adalah bagian dari *artificial intelligence* yang melatih algoritma dengan sistem *trial and error*. RL berinteraksi dengan lingkungannya dan memperhatikan akibat dari tindakannya, sebagai respons atas penghargaan atau hukuman yang diterimanya. Informasi yang diperoleh dari setiap interaksi dengan

lingkungan tersebut digunakan oleh RL untuk memperbarui pemahamannya (Andreanus & Kurniawan, 2018).

Deep Q-Network (DQN) adalah algoritma pembelajaran penguatan yang menggabungkan algoritma *Q-Learning* dan *Deep Neural Network* sebagai fungsi aproksimator. Dalam DQN, *Q-values* (nilai Q) digunakan untuk mengukur nilai tindakan dalam suatu keadaan. Jaringan saraf mendalam (*Deep Neural Network*) digunakan untuk memodelkan *Q-values* dalam DQN (Ridho Amanda Putra, 2024).

4. Analisis dan Diskusi

Analisis :

Pada *CartPole-v1*, tugas agen adalah menjaga keseimbangan tiang di atas gerobak/kotak selama mungkin. Lingkungan ini memberikan reward sebesar +1 untuk setiap langkah yang berhasil mempertahankan keseimbangan, sehingga proses pembelajaran dapat berlangsung lebih cepat. Selain itu, batas maksimal episode 1000 membuat agen memiliki banyak kesempatan untuk belajar dan menyempurnakan kebijakan yang lebih optimal.

Sebaliknya, *MountainCar-v0* menghadirkan tantangan yang lebih besar karena agen harus menggerakkan mobil melewati bukit/gunung dengan cara mengayun bolak-balik untuk mendapatkan momentum yang cukup. Tantangan utama pada lingkungan ini adalah sistem *reward*-nya yang lebih menantang, di mana agen hanya mendapatkan *reward* yang signifikan (+100) jika berhasil mencapai puncak, sementara langkah lainnya menghasilkan *reward* negatif yang membuat agen lebih sulit memahami strategi yang benar. Dengan batas maksimal 200 langkah per episode, agen harus belajar lebih cepat untuk mencapai solusi optimal dalam ruang tindakan yang lebih terbatas dibandingkan dengan *CartPole*.

Diskusi :

Perbedaan hasil pembelajaran pada *CartPole-v1* dan *MountainCar-v0* memperlihatkan bahwa setiap lingkungan memiliki karakteristik tersendiri yang berpengaruh terhadap strategi pelatihan agen. Lingkungan *CartPole-v1* cenderung lebih mudah dipelajari karena sistem *reward*-nya langsung memberikan umpan balik positif atas tindakan yang tepat, sehingga agen dapat lebih cepat beradaptasi dengan strategi eksplorasi yang efisien.

Sebaliknya, *MountainCar-v0* menuntut kesabaran lebih, sebab *reward* yang berarti baru diperoleh ketika agen berhasil mencapai tujuan. Struktur *reward* yang berbeda ini juga berdampak pada penggunaan *Experience Replay* dan *Target Network Update*. Pada *CartPole*, *replay* buffer berukuran kecil sudah memadai karena banyak pengalaman positif bisa terkumpul dalam waktu singkat. Namun, pada *MountainCar* dibutuhkan *replay buffer* yang lebih besar agar agen dapat mengumpulkan lebih banyak sampel dan memahami strategi jangka panjang. Dengan demikian, dapat disimpulkan bahwa penerapan *reinforcement learning* tidak bisa dilakukan secara seragam pada semua lingkungan, melainkan harus disesuaikan dengan karakteristik masing-masing agar proses pembelajaran agen berjalan optimal.

5. Assignment

Pada praktikum ini dilakukan pengujian agen *Deep Q-Network* (DQN) pada dua lingkungan berbeda, yaitu *CartPole-v1* dan *MountainCar-v0* menggunakan *OpenAI Gym* dan *TensorFlow*. Agen DQN memanfaatkan *Q-Network* dan *Target Network* untuk menentukan aksi optimal, serta *Experience Replay* untuk menyimpan pengalaman pembelajaran.

Pada *CartPole-v1*, agen diuji menjaga keseimbangan tiang di atas gerobak. Reward diberikan +1 setiap langkah, sehingga umpan balik positif sering diperoleh. Agen yang telah dilatih dari model *cartpole_dqn.h5* mampu menjaga keseimbangan lebih lama seiring bertambahnya episode, menunjukkan bahwa lingkungan dengan *reward*



yang sering dapat dipelajari lebih cepat dengan *replay buffer* kecil dan *epsilon decay* lebih cepat.

Sebaliknya, pada *MountainCar-v0*, agen harus memanfaatkan momentum untuk mencapai puncak bukit. Karena *reward* hanya muncul ketika tujuan tercapai, dilakukan reward shaping dengan tambahan nilai berdasarkan posisi mobil serta bonus +100 saat berhasil mencapai puncak. Hasil uji coba menunjukkan agen membutuhkan waktu lebih lama untuk belajar, namun secara bertahap mulai menemukan strategi yang efektif.

Dari kedua eksperimen ini dapat disimpulkan bahwa pemilihan parameter dalam *reinforcement learning* sangat dipengaruhi oleh karakteristik lingkungan. Lingkungan dengan *reward* sering seperti *CartPole* cocok dengan eksplorasi cepat dan *buffer* kecil, sedangkan *MountainCar* membutuhkan eksplorasi lebih panjang dan *buffer* besar agar agen dapat menemukan strategi optimal.

6. Data dan Output Hasil Pengamatan

No	Variabel	Hasil Pengamatan	
		Chart Pole-v1	Mountain Car-v0
1.	Waktu pelatihan	Chartpole dalam test episode 1 sudah mencapai 109, yang bisa di katakana lebih cepat dalam mencapai performa optimal.	Mountain car dalam test membutuhkan waktu lama untuk mendapatkan nilai yang tinggi atau nilai yang optimal.
2.	Kinerja agen	Kinerja yang optimal Ketika nilai yang lebih tinggi.	Dalam mountain car masih menghadapi tantangan untuk mencapai puncak bendera.
3.	Kondisi berhasil	Episode berakhir jika tiang jatuh atau batas langkah maksimum tercapai.	Episode berakhir jika mobil mencapai puncak bukit (bendera).

4.	Hasil episode		
		Test Episode: 1, Score: 109 Test Episode: 2, Score: 30 Test Episode: 3, Score: 20 Test Episode: 4, Score: 27 Test Episode: 5, Score: 23 Test Episode: 6, Score: 62 Test Episode: 7, Score: 63 Test Episode: 8, Score: 48	Test Episode: 1, Score: 35 Test Episode: 2, Score: 35 Test Episode: 3, Score: 49 Test Episode: 4, Score: 30 Test Episode: 5, Score: 66

7. Kesimpulan

Dari hasil praktikum ini dapat ditarik kesimpulan sebagai berikut :

1. *CartPole-v1* cenderung cepat dikuasai agen, karena umpan balik reward muncul terus-menerus di setiap aksi yang benar, sehingga proses belajar berlangsung lebih efisien. Nilai loss yang terus menurun menunjukkan bahwa proses training berjalan efektif.
2. *MountainCar-v0* menuntut proses belajar yang lebih panjang karena agen hanya memperoleh *reward* signifikan saat mencapai puncak, sehingga diperlukan eksplorasi lebih luas dan strategi yang lebih matang.
3. Penerapan *Target Network* berperan sebagai penyeimbang sehingga proses *update* nilai lebih terkendali dan hasil pelatihan tidak mudah melenceng.
4. *Experience Replay* memungkinkan agen belajar dari kumpulan pengalaman beragam, sehingga pola keputusan lebih matang meskipun proses latihannya lebih lambat.
5. Setiap lingkungan menuntut konfigurasi *hyperparameter* yang unik kombinasi yang tepat sangat menentukan seberapa cepat agen mencapai performa optimal.

8. Saran

Untuk meningkatkan performa agen, penggunaan *Prioritized Experience Replay* dapat diterapkan agar proses pembelajaran lebih fokus pada pengalaman yang paling berpengaruh. Pendekatan *Dueling DQN* juga bisa menjadi pilihan karena mampu memisahkan nilai keadaan dan aksi sehingga agen lebih efisien dalam menentukan keputusan. Selain itu, teknik *reward shaping* pada lingkungan seperti *MountainCar* akan membantu mempercepat agen dalam menemukan strategi optimal. Model juga dapat diperkuat dengan penerapan regularisasi pada jaringan saraf untuk mengurangi risiko *overfitting*. Terakhir, penyesuaian learning rate secara adaptif akan membuat pelatihan tetap stabil meskipun menghadapi tingkat kesulitan lingkungan yang berbeda.

9. Daftar Pustaka

- Andreanus, J., & Kurniawan, A. (2018). Sejarah, Teori Dasar dan Penerapan Reinforcement Learning: Sebuah Tinjauan Pustaka. *Jurnal Telematika*, 12(2), 113–118.
<https://doi.org/10.61769/telematika.v12i2.193>
- Ridho Amanda Putra. (2024). *ANALISIS DEEP Q-NETWORK (DQN) UNTUK SIMULASI LAMPU LALU LINTAS ADAPTIF BERDASARKAN WAKTU TUNGGU KENDARAAN*. POLITEKNIK CALTEX RIAU.
- Telaumbanua, F. D., Hulu, P., Nadeak, T. Z., Lumbantong, R. R., & Dharma, A. (2020). Penggunaan Machine Learning Di Bidang Kesehatan. *Jurnal Teknologi dan Ilmu Komputer Prima (JUTIKOMP)*, 2(2).
<https://doi.org/10.34012/jutikomp.v2i2.657>